

اليوم الثاني

دائرة التعلم

رحلة في دورة تدريب الآلة وتعديل الأوزان تلقائياً

بعد أن تعرفنا بالأمس على عجز البشر عن ضبط ملايين الأوزان يدوياً، نكتشف اليوم كيف نعطي الآلة بوصلة رياضية لتكتشف الأوزان الصحيحة بنفسها تلقائياً عبر دورة حياة التعلم.



"بالأمس، كافحنا وتعبنا لإيجاد الأوزان الصحيحة يدوياً.
واليوم، نعطي الآلة بوصلة ذكية — لتجدها وتعديلها بنفسها تلقائياً".

دائرة التعلم الذاتية (The Learning Loop)

بنهاية درس اليوم، ستتمكن من:

قياس الخسارة (Loss)

توضيح كيف تقوم الآلة بحساب وقياس نسبة الخطأ الدقيقة لتحديد مدى قربها من الحل الصحيح.

خطوات التدريب الأربعة

شرح وتحديد المراحل الأربعة الكبرى لتدريب الآلة: التخمين، القياس، التعديل، والتكرار.

الجسر المعرفي للغد

فهم لماذا تمثل هذه الدورة المغلقة الجسر المعرفي الأساسي لبناء الشبكات العصبية العميقة غداً.

التعديل التلقائي

وصف كيف تقوم الآلة بتعديل وتحديث الأوزان تلقائياً دون أي تدخل أو تعديل بشري يدوي.

01

التخمين العشوائي

كيف تبدأ الآلة رحلتها التعليمية عمياء بالكامل دون أي توجيه أو معرفة سابقة؟

مراجعة سريعة: كيف كنا نتخذ القرارات بالأمس؟

معادلة القرار الكلاسيكية



النتيجة =

الخاصية الاولى $\times$ الوزن + ١

الخاصية الثانية $\times$ الوزن + ٢

بالأمس، قمنا بضبط وزنين فقط ($W1, W2$) يدويًا للوصول لخط القرار الصحيح الذي يفصل بين القطط والكلاب.

ولكن، ماذا لو كان لدينا صورة حقيقية معقدة تحتوي على ملايين الخصائص والبكسلات؟


هذا يعني أننا سنحتاج إلى ملايين الأوزان المقابلة لها! وهو أمر مستحيل تماماً على أي مهندس بشري القيام به يدوياً. يجب أن نتعلم الآلة كيف تفعل ذلك تلقائياً.

البداية العشوائية: الآلة تبدأ عمياء تماماً

عندما تبدأ الآلة في تعلم حل مسألة جديدة، فإنها لا تملك أي ذكاء مسبق أو توجيه. إنها تبدأ عمياء تماماً!

التخمين العشوائي (Random Guess): لأنها لا تعرف الحل الصحيح، تقوم الآلة باختيار قيم عشوائية تماماً للأوزان (Weights) في البداية لتجربتها.

إنها لا تملك أي فكرة إن كانت هذه الأرقام العشوائية قريبة من الصواب أم بعيدة جداً عنه؛ إنها فقط تضع تخميناً أولياً لتبدأ منه رحلة التعلم الطويلة.



التخمين العشوائي في العمل: مسار البيانات الأولية الصامتة

المرحلة 01

دخول البيانات الخام

تستقبل الآلة المدخلات والصور الخام (مثل صورة قطعة) وتقوم بتحويل خصائصها الهندسية إلى أرقام صامتة.

المرحلة 02

تطبيق أوزان عشوائية

تضرب الآلة قيم الخصائص في أرقام عشوائية تماماً ثم اختيارها دون أي علم أو توجيه مسبق بالمشكلة.

المرحلة 03

خروج النتيجة الأولى

ينتج رقم نهائي يمثل التوقع الأول للآلة (وهو خاطئ بنسبة كبيرة جداً لعدم وجود أي تدريب مسبق).

النتيجة المتوقعة: خطأ فادح!

الآلة تبدأ عمياء تماماً دون أي توجيه؛ والتخمين الأول هو مجرد رمية نرد عشوائية في الظلام الدامس، ومن المستحيل أن تصيب الهدف دون المرور بدائرة التعلم!

كيف تبدو النتيجة الخاطئة؟

القسم الأول: التخمين العشوائي

توقعات الآلة العشوائية مقابل الإجابات الصحيحة الحقيقية

الصورة المدخلة	الإجابة الصحيحة الحقيقية ✓	توقع الآلة العشوائي الأول 🎲
الصورة 1	قطعة 🐱	كلب 🐶 ← خاطئ ❌
الصورة 2	كلب 🐶	كلب 🐶 ← صحيح
الصورة 3	قطعة 🐱	قطعة 🐱 ← صحيح
الصورة 4	كلب 🐶	قطعة 🐱 ← خاطئ ❌

الخلاصة: نجحت الآلة في تخمين صورتين من أصل 4 (نسبة خطأ 50%). الآلة الآن بحاجة لمعرفة "بكم هي بعيدة" عن الصواب لتحسن!



تحقق سريع — لماذا لا يكفي قول "صحيح" أو "خاطئ" للآلة؟

فكر وناقش: ?

لماذا لا يمكننا ببساطة إخبار الآلة: "لقد أخطأت في التخمين، حاولي مجدداً"؟

ما الذي تحتاجه الآلة فعلياً لكي تتحسن وتتعلم من خطئها؟

ناقش مع زملائك لمدة 30 ثانية...

الإجابة الصحيحة: ✓

الآلة تحتاج لمعرفة "المسافة والاتجاه" (رقم دقيق) وليس مجرد نعم أو لا:

-المسافة (كم هي بعيدة؟): بدون معرفة حجم الخطأ بدقة، لن تعرف الآلة كم يجب أن تعدل أوزانها (هل تعدلها كثيراً أم قليلاً؟).

-الاتجاه (أي طريق تسلك؟): تحتاج الآلة لمعرفة ما إذا كان يجب زيادة الأوزان أم إنقاصها للوصول للحل الصحيح.

مجرد قول "حاولي مجدداً" يترك الآلة تدور في حلقة مفرغة عشوائية دون أي تحسن حقيقي!

02

قياس الخطأ

كيف تقوم الآلة بحساب وقياس الفجوة الرقمية بين توقعاتها والحل الصحيح بدقة؟

الفجوة تسمى "الخسارة"

القسم الثاني: قياس الخطأ

الفجوة تسمى الخسارة: (Loss) قياس مدى الخطأ

الخسارة = (Loss) توقع الآلة - الإجابة الصحيحة

الإجابة الصحيحة (Correct Answer) ✓

الحقيقة والهدف الفعلي 🎯

هي القيمة الصحيحة الحقيقية التي نريد من الآلة الوصول إليها ومطابقتها بدقة.

توقع الآلة (Guess) 🎲

التخمين الحالي 🎲

هو الرقم أو التوقع الذي خمنته الآلة بناءً على قيم أوزانها العشوائية الحالية.

المهمة الوحيدة للآلة: 💡

المهمة الأساسية والوحيدة للآلة في هذه المرحلة هي جعل قيمة الخسارة (Loss) أصغر ما يمكن، أي تقليص الفجوة لتصل إلى الصفر!

مثال عملي: كيف نحسب قيمة الخسارة (Loss) ؟



"الخسارة = 0.6"

عملية الحساب البسيطة:

$$0.8 (\text{التوقع}) - 0.2 (\text{الحل}) = 0.6$$

هذه فجوة كبيرة جداً! الآلة الآن تعرف بدقة كم هي بعيدة عن الصواب، وستبدأ بتعديل أوزانها لتقليل هذه الفجوة في الجولة القادمة.

تخيل أننا ندرّب الآلة على التعرف على صورة قطة، وقمنا بصياغة المسألة رياضياً: **القطة = 0.2**،
والكلب = 0.8.

توقع الآلة (Guess): بسبب الأوزان العشوائية في البداية، توقعت الآلة أن الصورة هي كلب وأعطت قيمة **0.8**.


الحل الحقيقي (Truth): الصورة الحقيقية هي قطة، والقيمة الصحيحة المطلوبة هي **0.2**.

لماذا تهمنا قيمة الخسارة؟ الرقم يعطي اتجاهًا واضحًا

مجرد معرفة "أنت مخطئ (Just Wrong)"	✓ القياس الدقيق للخسارة (Loss Value)
تقول للآلة: "تخمينك كان خاطئاً، حاول مجدداً".	تقول للآلة: "تخمينك كان بعيداً بمقدار 0.6 عن الصواب".
لا تعطي الآلة أي اتجاه أو مسافة لتتحرك نحوها	تعطي الآلة إشارة واضحة للتحرك نحو الأرقام الأصغر
تظل الآلة تخمن عشوائياً دون قدرة حقيقية على التحسن	تستطيع الآلة تعديل الأوزان بدقة متناهية لتقليل الفجوة
تشبه قولك لصديقك: "حاول مجدداً" دون توجيه	تشبه قولك لصديقك: "تحرك 3 خطوات باتجاه اليمين"

الخلاصة: معرفة "أنت مخطئ" لا تفيدك برمجياً، بينما معرفة "كم أنت بعيد" تمنحك الاتجاه والمسافة الدقيقة لتصل للهدف!

منحنى الخسارة: كيف تنخفض الأخطاء مع التدريب؟



مع تكرار دورة التعلم وتعديل الأوزان تلقائياً، يحدث شيء مذهل لقيمة الخسارة: تبدأ الأخطاء بالانخفاض التدريجي!

منحنى الخسارة (Loss Curve): هو رسم بياني يوضح كيف تنخفض قيمة الخسارة مع زيادة جولات التدريب (من جولة واحدة إلى ملايين الجولات).

مرحلة الاستقرار (Plateau): يبدأ المنحنى مرتفعاً جداً (تخمينات خاطئة)، ثم ينحدر بسرعة، حتى يستقر في النهاية عند قيمة منخفضة جداً قريبة من الصفر. هنا نقول إن النموذج قد تم تدريبه بنجاح!

ماذا لو ظلت قيمة الخسارة (Loss) مرتفعة بعد التدريب؟

السبب الأول: البيانات سيئة أو غير كافية

مدخلات خاطئة تعني مخرجات خاطئة

إذا كانت صور التدريب منخفضة الجودة، أو تحتوي على أخطاء وتناقضات، فلن تتمكن الآلة من التعلم.

القاعدة الذهبية في هندسة البيانات: "Garbage In, Garbage Out": إذا قمت بتغذية الآلة ببيانات مشوشة أو خاطئة، فستظل قيمة الخسارة مرتفعة ولن تصيب الهدف أبداً.

السبب الثاني: النموذج بسيط جداً وضعيف

عجز عن فهم الأنماط المعقدة

النموذج لا يملك القدرة الكافية أو المعادلات الرياضية المناسبة لتمثيل وفهم تفاصيل الصورة المعقدة.

إذا حاولت استخدام خط مستقيم بسيط لفصل مجموعات متداخلة بشكل حلزوني معقد، فستفشل الآلة دائماً. النموذج البسيط جداً يعجز عن استيعاب عمق المشكلة.

⚠️ الخلاصة: بقاء الخسارة مرتفعة يعني أن الآلة لم تتعلم شيئاً! لحل المشكلة، يجب إما تحسين جودة البيانات أو زيادة تعقيد وعمق النموذج.

تحقق سريع — احسب قيمة الخسارة (Loss) بنفسك!

الإجابة الصحيحة: ✓

نقوم بالتعويض في معادلة الخسارة البسيطة:

$$\text{الخسارة (Loss)} = 0.9 - 0.3 = 0.6$$

تقييم النتيجة:

هذه نتيجة سيئة جداً! لأن قيمة الخسارة (0.6) مرتفعة وبعيدة جداً عن الصفر (الهدف المثالي).

← الآلة تحتاج للعديد من جولات التدريب وتعديل الأوزان لتتقرب من الصفر! 📉

فكر واحسب: 🧮

أثناء تدريب نموذج ذكاء اصطناعي، قام النموذج بالتوقع التالي:

-توقع الآلة: (Guess) القيمة = 0.9

-الإجابة الصحيحة المطلوبة: (Truth) القيمة = 0.3

ما هي قيمة الخسارة (Loss) في هذه الحالة؟ وهل هذه النتيجة جيدة أم سيئة؟

⌚ احسب مع زملائك في 30 ثانية...

03

التعديل التلقائي

كيف تقوم الآلة بتحديث وتعديل أوزانها تلقائياً دون أي تدخل بشري؟

البوصلة الذكية: كيف تندمج الخسارة والتعديل معاً لتوجيه الآلة؟



"البوصلة الرقمية للتعلم"

الخسارة تعطي المسافة
والتعديل يعطي الاتجاه

معاً، يشكلان بوصلة ذكية تقود الآلة خطوة بخطوة نحو الهدف الصحيح دون تشتت أو عشوائية!

كيف تخرج الآلة من عشوائية البداية وتتحرك بثقة نحو الحل الصحيح؟ السر يكمن في دمج الخسارة والتعديل معاً!

الخسارة (Loss) تعطي المسافة: تخبر الآلة بدقة بمدى بعدها عن الحل الصحيح (مثلاً: "أنت بعيدة بمقدار 0.6 عن الهدف").

قانون التعديل (Adjustment Rule) يعطي الاتجاه: يخبر الآلة بالاتجاه الصحيح للحركة (مثلاً: "يجب إنقاص الأوزان للوصول للهدف").

خطوات التعديل التلقائي: كيف تقوم الآلة بتحديث أوزانها؟

الخطوة 01

حساب الخسارة

تقوم الآلة بحساب الفجوة الرقمية الدقيقة بين توقعها الحالي والحل الصحيح المطلوب (مثلاً: الخسارة = 0.6).

الخطوة 02

تحديد الاتجاه

تحدد الآلة رياضياً ما إذا كان يجب زيادة قيم الأوزان أم إنقاصها لتقليل هذه الفجوة والاقتراب من الصفر.

الخطوة 03

التعديل البسيط

تقوم الآلة بتعديل قيم الأوزان ($W1$, $W2$) بقيمة صغيرة جداً وتدرجية في الاتجاه الصحيح الذي يقلل الخطأ.

سر النجاح في التعديل:

التعديل يتم دائماً بقيم صغيرة جداً وتدرجية (وليس بقفزات كبيرة) لضمان عدم تخطي الهدف الصحيح، والاقتراب منه بثبات جولة تلو الأخرى!

معدل التعلم (Learning Rate): ما هو حجم خطوة التعديل المناسب؟

معدل التعلم	الأثر والنتيجة على الأوزان	المشكلة والخلل الناتج
كبير جداً (Too Large)	تقوم الآلة بقفزات وتعديلات ضخمة وسريعة جداً للأوزان.	تتخطى الهدف: (Overshoot) تقفز فوق الحل الصحيح وتستمر بالقفز دون استقرار.
صغير جداً (Too Small)	تقوم الآلة بتعديلات متناهية الصغر وبطيئة للغاية للأوزان.	بطء شديد: (Too Slow) يستغرق التدريب وقتاً طويلاً جداً (أيام أو أسابيع) للوصول للحل.
متوازن ومناسب (Just Right)	تقوم الآلة بخطوات ثابتة ومدروسة تقترب بها تدريجياً من الهدف.	استقرار مثالي: (Convergence) تصل الآلة للحل الصحيح بأقل عدد ممكن من الجولات وبكفاءة عالية.

الخلاصة: اختيار معدل التعلم (Learning Rate) الصحيح هو أحد أهم المهارات الرياضية والهندسية في تدريب نماذج الذكاء الاصطناعي!



مشكلة تخطي الهدف (Overshooting): عندما تكون الخطوة أكبر من اللازم



"التأرجح دون استقرار!"


تخيل أنك تحاول إيقاف سيارتك في موقف محدد بدقة، ولكنك تضغط على دواسة الوقود بقوة مفرطة وخطوات واسعة؛ ستظل تتجاوز الموقف يميناً ويساراً دون الاستقرار فيه أبداً!

ماذا يحدث لو قمنا بزيادة حجم خطوة التعديل (Learning Rate) بشكل مفرط لتسريع عملية التعلم؟ هنا نقع في مشكلة تخطي الهدف!

القفز فوق الهدف: بدلاً من الهبوط التدريجي والامن لقيمة الخسارة نحو الصفر، تجعل الخطوات الواسعة جداً الآلة تقفز فوق الحل الصحيح وتتخطاه تماماً إلى الجانب الآخر.

التأرجح اللانهائي: تظل الآلة تتأرجح وتتذبذب يميناً ويساراً فوق الهدف دون أن تستقر أبداً عند القيمة المثالية؛ مما يجعل عملية التدريب فاشلة وغير مستقرة.

دورة التدريب الكاملة: كيف تتعلم الآلة تلقائياً؟



دورة حياة التعلم الذاتي:

هذه الخطوات الأربعة البسيطة تتكرر ملايين المرات تلقائياً وبسرعة فائقة، وهي السر الكامن وراء قدرة كل أنظمة الذكاء الاصطناعي الحديثة على التعلم والتميز!

مقارنة الجهد: أنت بالأمس مقابل الآلة اليوم

وجه المقارنة	أنت بالأمس (الضبط اليدوي)	الآلة اليوم (الضبط التلقائي)
تحديد الأوزان الأولى	قمت بتخمين الأوزان الأولى بناءً على حدسك البشري	تضع أرقاماً عشوائية تماماً كنقطة انطلاق صامتة
حساب نسبة الخطأ	نظرت إلى النتيجة وقدرت الفجوة بعينيك وعقلك	تحتسب قيمة الخسارة (Loss) بمعادلة رياضية دقيقة
تعديل قيم الأوزان	قمت بتحريك المؤشرات يدوياً بناءً على تجربتك	تعدل الأوزان تلقائياً بقيم صغيرة في الاتجاه الصحيح
القدرة على الاستمرار	شعرت بالتعب والملل بعد 10 جولات من المحاولة	لا تتعب ولا تمل أبداً؛ وتستمر في المحاولة بلا كلل
السرعة والتكرار	استغرقت 10 دقائق لتجربة بضعة جولات بسيطة	تكرر الدورة ملايين المرات في أجزاء من الثانية

الخلاصة: الآلة تفعل نفس ما فعلته أنت بالأمس تماماً، ولكن بسرعة فائقة ودون تعب أو توقف لتقترب من الحل المثالي!

قوة التوسع الهائل: الفارق الحقيقي بين الإنسان والآلة

👤 الجهد البشري اليدوي (أنت بالأمس)

وزنان فقط ⚖️ ($W1, W2$)

استغرق منك ضبط وزنين فقط يدوياً حوالي 10 دقائق من التركيز والتجربة المستمرة.

العقل البشري يملك الحكمة والفهم العميق، ولكنه بطيء جداً في إجراء الحسابات الرياضية المتكررة والمملة؛ ويتعب بسرعة بعد جولات قليلة.

☰ القدرة الحسابية للآلة (التعلم التلقائي)

1.8 تريليون وزن 🇸🇪 !

قام نموذج GPT-4 بضبط وتعديل 1.8 تريليون وزن تلقائياً خلال أيام معدودة وبدقة متناهية.

الآلة لا تملك وعياً أو فهماً حقيقياً، ولكنها تملك سرعة حسابية خارقة تمكنها من تكرار نفس العملية الرياضية البسيطة تريليونات المرات دون تعب أو توقف!

الخلاصة: الفارق الحقيقي ليس في الذكاء أو الوعي؛ بل في القدرة الهائلة للآلة على تكرار نفس الخطوات الأربعة البسيطة تريليونات المرات تلقائياً وبسرعة فائقة!



ماذا يحدث للأوزان بعد انتهاء التدريب بنجاح؟



1. تجميد الأوزان ❄️

عندما تقترب قيمة الخسارة من الصفر، تتوقف عملية التعديل التلقائي ويتم قفل وتجميد قيم الأوزان نهائياً لمنع أي تغيير إضافي عليها.



2. تعبئة وحفظ النموذج 📦

يتم حفظ وتعبئة قيم الأوزان المجمدة والنهائية داخل ملف رقمي بسيط يمثل "عقل" نموذج الذكاء الاصطناعي الجاهز للعمل.



3. التشغيل في الواقع 🚀

يتم تشغيل النموذج في الواقع ليعطي توقعات فورية ودقيقة على بيانات وصور جديدة تماماً لم يرها من قبل أثناء عملية التدريب.

تحقق سريع — تشخيص مشكلة ثبات الخسارة!

التشخيص الهندسي الصحيح: ✓

1. جودة البيانات منخفضة جداً: (Bad Data)

صور التدريب قد تكون مشوشة، أو غير كافية، أو تحتوي على تناقضات تمنع الآلة من استخراج أي نمط مفيد. (Garbage In, Garbage Out)

2. النموذج بسيط وضعيف جداً: (Weak Model)

النموذج لا يملك القدرة الكافية أو المعادلات الرياضية المناسبة لفهم الأنماط المعقدة في الصورة، ويحتاج لزيادة عمقه وتراكم طبقاته.

❓ فكر وشخص:

الآلة تتدرب منذ 1,000 جولة كاملة، ولكن قيمة الخسارة (Loss) ثابتة عند 0.85 ولا تنخفض أبداً.

ما هما السببان الأكثر احتمالاً لحدوث هذه المشكلة في التدريب؟

ناقش مع زملائك في 30 ثانية... ⌚

04

الجسر إلى الدماغ البشري

كيف يقودنا التعديل التلقائي للأوزان إلى محاكاة الخلايا العصبية ودماغ الإنسان؟

حدود المعادلة الخطية: لماذا تعجز الصيغة البسيطة عن فهم العمق؟



"الصيغة الخطية تنهار!"

المعادلة المسطحة تسأل سؤالاً واحداً بسيطاً ومباشراً، بينما يحتاج فهم ملامح الوجه البشري المعقدة إلى سلسلة متراكمة وعميقة من الأسئلة المتداخلة التي لا يمكن صياغتها في سطر واحد!

دائرة التعلم والأوزان التي درسناها اليوم رائعة جداً، ولكنها تواجه عقبة كبرى: إنها الخطية وبسيطة للغاية!

المعادلة الخطية: (Flat Equation) ممتازة لحل المشكلات البسيطة التي تحتوي على خاصيتين أو عشر خصائص واضحة ومباشرة (مثل زاوية الأذن وعرض الجسم).

عجز أمام الأنماط المعقدة: ولكن ماذا لو أردنا تمييز ملامح وجه بشري؟ الوجه يحتوي على ملايين الخصائص المتداخلة والمتغيرة باستمرار. الصيغة الخطية البسيطة تعجز تماماً عن استيعاب هذا العمق والتعقيد البصري.

ماذا يعني العمق والطبقات؟ الفارق بين التفكير المسطح والعميق

الهيكل العميق (Deep Structure)

أسئلة متدرجة ومتراكمة

طبقات متعددة متراكمة تسأل أسئلة متدرجة (الطبقة 1: هل توجد حواف؟ ← الطبقة 2: هل تشكل أشكالاً؟).

هذا هو جوهر **التعلم العميق (Deep Learning)**؛ حيث تقوم كل طبقة بحل جزء بسيط من المشكلة وتمير النتيجة للطبقة التالية، مما يسمح بفهم الأنماط بالغة التعقيد.

الهيكل المسطح (Flat Structure)

سؤال واحد بسيط ومباشر

طبقة واحدة من الأوزان تسأل سؤالاً واحداً فقط (مثل: هل توجد بكسلات داكنة هنا؟).

هذا الهيكل البسيط يعجز تماماً عن فهم التفاصيل المعقدة؛ لأنه يحاول حل المشكلة دفعة واحدة دون تفكيكها إلى أجزاء صغيرة، مما يجعله غير فعال للصور الحقيقية.

الخلاصة: الهيكل المسطح يسأل سؤالاً واحداً بسيطاً، بينما الهيكل العميق يفكك المشكلة إلى طبقات متراكمة من الأسئلة الذكية لحل أعقد الأنماط البصرية!



الهيكل مستوحى من الدماغ البشري: من البيولوجيا إلى التكنولوجيا



"دماغك هو الملهم!"

الدماغ البشري هو الملهم الحقيقي لثورة التعلم العميق والشبكات العصبية الاصطناعية!


غداً في اليوم الثالث، سنغوص في أعماق هذا الهيكل المذهل تحت عنوان "مبني على صورتنا!"

من أين استوحى علماء الحاسوب فكرة تراكم الطبقات العميقة لحل المشكلات المعقدة؟ الإجابة تكمن داخل رؤوسنا!

الدماغ البشري (Human Brain): يحتوي على حوالي 86 مليار خلية عصبية (Neurons) متصلة ببعضها البعض في شبكة معقدة وعميقة للغاية تتواصل عبر إشارات كهربائية.

التعلم البيولوجي: تزداد قوة الوصلات والروابط بين الخلايا العصبية مع كل تجربة وتعلم جديد؛ وهو ما يحاكيه تماماً نموذج الأوزان والتعلم التلقائي في الذكاء الاصطناعي.

ملخص اليوم الثاني: دائرة التعلم الكاملة في صورة واحدة



دورة حياة التعلم الكاملة:

تبدأ الآلة عمياء بالتخمين العشوائي، وتقيس خطأها بالخسارة، وتعديل أوزانها تلقائياً وتكرر الدورة ملايين المرات، حتى تقترب الخسارة من الصفر وتتجمد الأوزان لينتج لدينا نموذج ذكي جاهز للعمل في الواقع!

الفكرة الكبرى لليوم

بالأمس، قمت بضبط الأوزان يدوياً خطوة بخطوة لتوجيه خط القرار.

واليوم، تعلمت الآلة كيف تضبط وتعديل أوزانها تلقائياً وبسرعة فائقة عبر **دائرة التعلم الذاتي**.

غداً: سنتعلم كيف نبني الهيكل والشبكة العصبية العميقة التي تعيش فيها هذه الأوزان لتدرك العالم!



ماذا ينتظرنا غداً؟

في اليوم الثالث والدرس القادم، سننتقل من دائرة التعلم التلقائي إلى محاكاة العقل البشري وبناء الشبكات العصبية.

"اليوم الثالث: مبني على صورتنا"